

저작권양도서

(Copyright Transfer Form)

소속 : 인하대학교 정보통신공학과

성명 : 김기원, 곽준형, 서주형 학번 : 12181737, 12201850, 12181784

논문제목 : 어텐션 기반의 다이내믹 윈도우를 사용한 음성 데이터 전처리 기법

본인은 상기 논문을 2023학년도 1학기 정보통신프로젝트 최종 보고서 겸 결과 논문으로 제출하고자 합니다. 본 논문의 내용은 저자가 직접 연구한 결과인 것과 이전에 출판된 적이 없음을 확인합니다. 또한 공저자와 더불어 인하대학교 정보통신공학부에서 발간하는 논문집에 본 논문을 수록하는 것을 허락하며 제반 저작권을 정보통신공학부에 양도합니다.

2023년 6월 22일

저자 :

김기원



곽준형



서주형



정보통신공학과장 귀하

저작권양도서

(Copyright Transfer Form)

소속 : 인하대학교 정보통신공학과

성명 : 김기원, 곽준형, 서주형 학번 : 12181737, 12201850, 12181784

논문제목 : 어텐션 기반의 다이내믹 윈도우를 사용한 음성 데이터 전처리 기법

본인은 상기 논문을 2023학년도 1학기 정보통신프로젝트 최종 보고서 겸 결과 논문으로 제출하고자 합니다. 본 논문의 내용은 저자가 직접 연구한 결과인 것과 이전에 출판된 적이 없음을 확인합니다. 또한 공저자와 더불어 인하대학교 정보통신공학부에서 발간하는 논문집에 본 논문을 수록하는 것을 허락하며 제반 저작권을 정보통신공학부에 양도합니다.

2023년 6월 22일

저자 :

김기원

 (김기원)

곽준형

 (곽준형)

서주형

 (서주형)

정보통신공학과장 귀하

어텐션 기반의 다이나믹 윈도우를 사용한 음성 데이터 전처리 기법

Audio Data Preprocessing Technique Using Attention-Based Dynamic Window

김기원, 곽준형, 서주형
(Giwon Kim and Joonhyung Kwak and Juhyeong Seo)

요약: 일반적인 전처리 기법은 길이가 다른 음성 데이터를 처리하는데 있어 중요 정보의 손실이나 데이터 길이 증가로 인한 계산 복잡성이 증가하는 문제가 있다. 어텐션 메커니즘을 이용하여 음성 데이터 내 중요 부분을 나타내는 어텐션 가중치를 추출한다. 본 연구에서 제안하는 기법인 다이나믹 윈도우 알고리즘을 통해 중요 부분을 포함하는 윈도우의 위치를 찾아 학습에 활용한다. 이를 통해 중요 정보의 손실을 최소화하여 음성 데이터의 학습 효율과 모델의 성능을 높인다.

Abstract : Typical preprocessing techniques suffer from the loss of important information when dealing with speech data of different lengths, or the increase in computational complexity as the data length increases. Attention mechanism is used to extract the attention weights that represent the important parts of the speech data. The technique proposed in this study, the dynamic window algorithm, locates windows containing important parts and uses them for learning. This minimizes the loss of important information and improves the learning efficiency of speech data and the performance of the model.

Keywords: Preprocessing techniques, TIM-NET, DW-Former, Attention mechanism, Dynamic window algorithm, Computational complexity, Learning efficiency

1. 서론

1. 음성 데이터 전처리의 필요성

음성 데이터는 감정 인식, 음성 합성, 스피커 인식, 음성 인식 등의 광범위한 분야에서 핵심적인 역할을 수행한다. 이러한 음성 기반 응용 분야들은 현재 우리 일상 생활과 점차 더 밀접하게 연결되고 있으며, 인공지능과 딥러닝 기술의 빠른 발전으로 인해 그 중요성이 지속적으로 상승하고 있다. 그러나 이러한 고도의 응용을 가능하게 하는 핵심적인 요소 중 하나는 적절한 데이터 전처리 과정이다.

음성 데이터는 그 복잡성과 독특한 특성으로 인해 다른 유형의 데이터에 비해 전처리 과정이 더욱 중요하고 복잡하다. 음성 데이터는 시간에 따라 변화하는 연속적인 신호로 이루어져 있으며, 발화자의 말 속도, 악센트, 강세 등에 따라 그 특성이 크게 변할 수 있다. 이러한 다양한 요소들로 인해 음성 데이터는 일정한 길이를 갖지 않게 되며, 이는 모델 학습을 어렵게 만드는 주요 요인 중 하나이다. 데이터의 길이가 일정하지 않으면, 배치 처리를 효율적으로 수행하기 어려워지고, 모델의 구조를 설계하는 것도 복잡해진다. 따라서, 음성 데이터를 처리하는 데 있어 효과적인 전처리 과정이 필수적이다.

2. 기존 전처리 기법과 문제점

음성 데이터 전처리의 기본적인 전략은 모든 음성 클립을 동일한 길이로 통일함으로써 데이터의 일관성을 유지하는 것이다. 현재까지 적용된 전처리 기법들은 대체로 두 가지 방식으로 분류되지만, 이들은 중요 정보의 손실과 메모리 사용량 증가라는 두 가지 중대한 문제점을 내포하고 있다.

첫 번째 방식은 데이터셋의 평균 길이로 데이터를 잘라내는 방법이다. 이 방법은 데이터의 일관성을 유지하는 데는 유용하나, 평균 길이를 초과하는 데이터는 잘라내야 한다. 이때, 음성 데이터의 특성상 신호의 흐름에 따라 중요 정보가 분산되어 있기 때문에 데이터를 임의로 잘라내는 것은 중요한 정보를 놓칠 위험이 있다.

두 번째 방식은 데이터셋의 최대 길이에 맞추는 방법이다. 이 방법은 중요 정보의 손실 문제를 해결할 수 있지만, 대부분의 데이터가 최대 길이에 미치지 못하는 경우 과도한 메모리 사용량을 초래할 수 있다. 이 방법에서 데이터의 빈 부분은 패딩(padding)으로 채워지기 때문에, 모델이 많은 계산을 불필요한 부분에 쏟아부을 수 있어 학습 효율이 저하될 수 있다.

3. 본 연구의 필요성

중요 정보의 손실과 메모리 사용량 증가라는 기존 전처리 방식의 두 가지 문제점을 고려하여, 새로운 전처리 방법의 도입과 기존 방식의 개선이 필요하게 되었다. 이러한 상황을 해결하기 위해, 본 연구에서는 "어텐션 기반의 다이나믹 윈도우를 사용한 음성 데이터 전처리 기법"을 제시하였다. 이 기법은 어텐션 메커니즘을 활용하여 음성 데이터의 복잡성을 고려하고, 중요한 정보를 최대한 보존하는 동시에 데이터의 길이를 데이터셋의 평균 길이로 일관되게 유지하는 방법을 제안하였다. 더불어, "중요 패턴 패딩 기법"을 통해 음성 데이터가 중요 정보를 더 많이 함양할 수 있도록 하는 새로운 패딩 방식을 도입하였다.

본 연구의 중요성은 문제 해결을 넘어서 음성 데이터 전처리 기법의 새로운 가능성을 제시하고 있다는 점에서 두드러진다. 이는 처리 속도와 메모리 효율성을 개선하고, 모델의 성능을 향상시키는 방식으로 직접적으로 이어진다. 또한, 제안하는 전처리 기법은 음성 인식, 분류 문제 등 다양한 음성 데이터 관련 분야에 적용 가능하므로, 이러한 분야의 연구 및 응용에 대한 새로운 방향을 제시하는 계기가 될 수 있다.

4. 본 연구의 목표

본 연구의 첫 번째 목표는 기존 음성 데이터 전처리 기법의 한계를 극복하는 새로운 전처리 기법을 개발하는 것이다. 본 연구에서는 어텐션 메커니즘을 활용하여 중요 정보를 보존하면서 데이터의 길이를 일관되게 유지하는 방향을 추구한다.

두 번째 목표는 "중요 패턴 패딩 기법"을 도입하여 제로 패딩이 가져오는 문제점을 해결하는 것이다. 이 기법은 음성 데이터의 중요 패턴을 파악하고 이를 기반으로 패딩을 적용함으로써, 제로 패딩이 가져오는 메모리 비효율성과 학습 효율의 저하 문제를 개선하려 한다.

마지막 목표는 이 새로운 전처리 기법이 모델의 성능을 향상시키는 데 얼마나 효과적인지를 확인하는 것이다. 이를 위해 현재 음성 데이터에 대한 감정 인식 분야에서 SOTA를 달성하고 있는 TIM-Net[1] 모델을 사용하여 실험을 진행하고, 기존의 전처리 방법과 비교하여 기법의 효과를 분석한다. 이를 통해 처리 속도와 메모리 효율성을 개선하고, 동시에 모델의 성능도 향상시키는 전처리 기법의 필요성과 중요성을 강조하려 한다.

II. 본론

1. 관련 연구

1.1 감정 분류 모델 TIM-Net

최근 감정 인식 분류 모델로서 주목받고 있는 TIM-Net은 여러 음성 데이터 벤치마크에서 뛰어난 성능을 보여주며 최고 수준(State-of-the-Art, SOTA)을 달성하였다. 이 모델은 다양한 형태의 음성 표현을 포착하는데 초점을 맞추어 심층 임베딩을 학습하고, 여러 감정 상태를 정확하게 인식할 수 있다. Transformers와 Integrated Multi-scale features라는 전략을 통해 다양한 스케일의 음성 특성을 함께 고려하며, 자기 주의 메커니즘을 활용

하여 음성 데이터 내의 중요한 패턴을 잘 파악한다. 이를 통해 섬세한 감정 인식 성능을 발휘한다.




그림 1. TIM-Net Network

TIM-Net의 네트워크 구조는 복잡한 음성 데이터를 분석하고 감정을 정확하게 분류하는 데 매우 효과적이다. 그림 1에서 확인할 수 있듯이, TIM-Net의 핵심 구성 요소는 다음과 같다.

먼저, Input Pipeline에서 음성 데이터는 Mel-frequency cepstral coefficients(MFCC)를 이용해 특징 벡터로 변환한다. MFCC는 음성 인식에서 널리 사용되는 특징 추출 방법으로, 사람의 청각 시스템이 특정 주파수 영역에 더 민감하게 반응하는 특성을 반영한다.

그 후, Temporal-aware Bi-direction Multi-scale Network(TIM-Net)는 Temporal-Aware Block 구조를 이용해 음성 데이터의 시간적 특성을 반영하고, 양방향성을 통해 과거와 미래의 정보를 동시에 고려한다. 또한, Multi-scale approach를 통해 다양한 시간 스케일의 패턴을 포착한다.

다음으로, Dynamic Fusion에서는 TIM-Net의 출력을 받아 Class-Discriminative Feature로 변환한다. 이 과정은 각 클래스(감정)에 따른 데이터의 차별적인 특성을 포착하고, 이를 통해 각 클래스를 더 잘 구별할 수 있도록 한다.

마지막으로, Classifier는 Dynamic Fusion에서 얻은 피쳐들을 분류기에 입력하여 최종적인 감정 분류를 수행한다.

이런 구조를 통해 TIM-Net은 음성 데이터의 다양한 특성과 시간적 패턴을 잘 파악하고 이를 바탕으로 감정을 정확하게 분류한다는 뛰어난 성능을 보인다. 본 연구에서는 성과를 확인하기 위한 평가 지표로 TIM-Net을 채택하였다. 기존 전처리 기법을 사용한 데이터셋과 제안하는 전처리 기법을 사용한 데이터셋을 통해 각각 TIM-Net 모델을 학습시키고 성능을 비교한다.

1.2 어텐션 기반 감정 분류 모델 DW Former

감정 인식 분류모델인 DW Former[2]는 트랜스포머 기반의 모델이며 감정에 대한 어텐션 맵을 추출하여 학습에 활용한 모델이다. 본 논문에서는 해당 모델이 다른 어텐션, 트랜스포머 모델에 비해 감정과 관련이 깊은지에 대한 어텐션맵을 신뢰성 있게 추출할 수 있다고 말하고 있다.




그림 2. DW Former Network

DLWT(Dynamic Local Window Transformer), DGWT(Dynamic Global Window Transformer) 두가지 트랜스포머 모듈로 이루어진 DW Former Block을 활용하여 중요 부분을 찾아내고 마스킹을 진행한다.

본 연구에서는 마지막 DW Former Block의 결과를 추출하여 중요한 정보의 위치를 찾는 데 사용한다.

2. 기존 전처리 정의

기존의 전처리 기법은 TIM Net에서 사용하는 전처리 기법을 참고하여 명명하였다. 해당 전처리 기법은 음성 데이터셋을 처리하는 과정에서 다음과 같은 단계를 포함한다.

1. 데이터셋의 평균길이 맞추는: 데이터셋의 음성 데이터들은 다양한 길이를 가지고 있다. 따라서 데이터의 일관된 길이를 유지하기 위해 평균길이에 맞추는 작업이 수행된다.

2. 데이터 자르기: 평균길이에 맞게 음성 데이터의 중간부분을 선택하여 자른다. 이를 통해 데이터셋의 일관된 길이를 유지하면서 데이터의 중요한 부분을 보존한다.

3. 패딩: 데이터의 길이가 평균길이보다 짧은 경우, 데이터의 앞과 뒤를 0으로 패딩하여 일관된 길이를 유지한다. 이를 통해 데이터셋 내 모든 데이터의 길이가 동일하게 맞춰지게 된다.

기존 전처리 기법은 TIM Net에서 사용한 전처리 기법을 기반으로 설계되었으며, 이후 연구들과의 비교 및 성능 평가를 위해 사용되었다.

3. 어텐션 기반의 다이내믹 윈도우 기법

연구에서 제안하는 어텐션 기반의 다이내믹 윈도우(Dynamic Window) 기법은 앞서 언급된 DW Former를 활용하여 각 음성 데이터에서 어텐션 가중치를 추출하고 중요한 부분을 파악하는 과정을 수행한다. 해당 기법은 다음과 같은 절차로 이루어진다.

1. 어텐션 가중치 추출: DW Former를 이용하여 각 음성 데이터에서 어텐션 가중치를 추출한다. 어텐션 메커니즘을 활용하여 음성 데이터의 중요한 부분을 감지하고 각 부분에 대한 가중치를 계산한다.

2. 윈도우 이동: 추출된 어텐션 가중치를 기반으로 윈도우를 이동시킨다. 윈도우는 어텐션 가중치가 가장 높은 부분을 포함하도록 조정된다. 이를 통해 음성 데이터의 핵심적인 부분을 윈도우 내에 위치시킨다.

3. 데이터 잘라내기: 윈도우에 맞게 데이터를 잘라낸다. 윈도우 내에 위치한 중요한 부분을 유지하면서, 데이터셋의 평균 길이에 일관성을 유지하기 위해 데이터를 조정한다.

어텐션 기반의 다이내믹 윈도우 기법은 음성 데이터 처리에서 중요한 정보의 손실을 최소화하고 데이터셋의 일관된 길이를 유지하는 기법이다. 이 기법은 DW Former의 어텐션 메커니즘을 활용하여

음성 데이터의 핵심을 추출하고 이를 기반으로 데이터를 조정한다.

4. 중요 패턴 패딩 기법

중요 패턴 패딩 기법은 데이터가 데이터셋의 평균 길이에 미치지 못하는 경우, 길이를 맞추기 위해 패딩을 적용하는 방법이다. 이 기법은 다음과 같은 절차로 이루어진다.

1. 데이터셋 평균 길이 미만인 경우 패딩: 원본 데이터가 데이터셋의 평균 길이에 미치지 못하는 경우, 패딩을 적용한다. 이를 통해 모든 데이터가 동일한 길이를 갖게 된다.

2. 중요 부분의 정보를 패딩 값에 반영: 단순히 0으로 패딩하는 것이 아니라, DW Former를 이용하여 찾아낸 중요 부분의 정보를 패딩 값에 반영한다. DW Former는 어텐션 기반으로 중요한 부분을 감지하고 가중치를 계산하는 역할을 수행한다. 이를 활용하여 중요 부분을 기준으로 패딩 값을 결정한다.

3. 원본 데이터의 중요 특성 유지: 중요 패턴 패딩은 패딩된 부분이 원본 데이터의 중요 특성을 유지할 수 있도록 한다. 패딩 값은 중요 부분의 정보를 반영하므로, 패딩된 부분이 원본 데이터의 핵심적인 특징을 가질 수 있게 된다.

중요 패턴 패딩 기법을 사용함으로써 데이터의 전체 정보에 미치는 패딩의 영향을 줄이고 더욱 효과적인 학습이 가능해진다. 패딩된 데이터는 데이터셋의 일관된 길이를 유지하면서도 중요한 패턴과 특징을 보존하게 된다.

5. 실험

5.1 데이터셋

데이터셋은 AI hub의 감성 및 발화 스타일별 음성합성 데이터를 사용한다. 기쁨, 놀람, 슬픔, 분노, 두려움, 혐오, 중립의 7가지 라벨로 이루어져 있으며 총 1,067시간으로 구성되어 있다.

전처리 기법 실험을 위해 각 라벨별 10,000개의 데이터를 랜덤으로 선별하여 70,000개의 데이터와 라벨로 이루어진 데이터 셋을 구축하였다. 추가로 전처리 기법중 사용되는 DW Former의 학습을 위해 앞의 70,000개의 데이터를 제외한 별도의 70,000개의 데이터를 랜덤으로 선별하여 총 70,000개 데이터 두 세트를 구축하였다. 여기서 구축된 데이터 셋은 1 ~ 7초의 다양한 길이를 가지고 있다.

5.2 전처리

실험을 위해 데이터셋은 ①MFCC + 기존전처리, ②WavLM + 기존전처리, ③WavLM + 다이내믹윈도우, ④WavLM + 다이내믹윈도우 + 중요패턴패딩 4가지 기법으로 전처리되어 저장된다.

5.1.1 MFCC + 기존전처리

첫번째 전처리 기법은 실험을 진행할 모델인 TimNet의 전처리 기법을 따른다. 음성을 TimNet의 기존 전처리 기법을 통해 평균 길이로 맞추고 MFCC

변환을 수행한다.

5.1.2 WavLM + 기존전처리

음성 특징을 구하는 방법으로 학습된 WavLM모델의 중간 레이어의 결과를 사용하는 기법을 사용하였다. WavLM은 정보가 손실된 음성을 복원하도록 하는 large-scale 자기지도학습 모델로 음성 특징을 찾아내는데 사용된다.

WavLM의 결과의 평균 길이를 구하여 기존 전처리 기법을 적용한다.

5.1.3 WavLM + 다이نام릭윈도우

WavLM 으로 변환된 음성을 미리 학습된 DWFormer 모델의 입력으로 하여 어텐션 맵을 추출한 뒤 다이نام릭 윈도우 알고리즘을 적용한다. 이 과정에서 구해진 윈도우의 시작 인덱스를 이용해 데이터의 길이를 맞추는 전처리를 한다. 여기서 음성 데이터의 길이가 평균 길이에 미치지 못하는 경우 '0'으로 패딩한다.

5.1.4 WavLM + 다이نام릭윈도우 + 중요패턴패딩

위 5.1.3의 방식과 동일하나 음성 데이터의 길이가 평균 길이에 미치지 못하는 경우 중요 패턴 패딩을 적용한다.

5.3 실험 결과

위 네가지 전처리 기법은 감정 분류 모델 TIM-Net을 학습시킨 결과로 평가한다. 학습 파라미터와 실험 결과는 아래의 <표 1>, <표 2>와 같다.

<표 1 TIM-Net 학습 파라미터>

하드웨어	RTX 3080 16G
epoch	30
batch size	16
optimizer	Adam
learning rate	0.001

<표 2 전처리 기법에 따른 성능 비교 결과>

모델	기법	Acc	F1-score
TIM-Net	MFCC + 기존 전처리	0.642	0.594
	WavLM + 기존 전처리	0.828	0.829
	WavLM + 다이نام릭 윈도우	0.857	0.858
	WavLM + 다이نام릭 윈도우 + 중요 패턴 패딩	0.844	0.845

III. 결론

본 연구에서는 성능 평가를 위해 본 연구에서는 4가지 실험을 시행하였다. 사용된 기법은 다음과 같다. TIM-Net이 원래 음성 데이터를 특징 벡터로 변환하는데 사용하는 MFCC와 기존 전처리 기법, 음성 feature 처리를 위한 large-scale 자기지도학습의 pre-trained된 모델인 WavLM과 기존 전처리 기법, WavLM과 본 연구에서 제안하는 다이نام릭 윈도우 전처리 기법, 그리고 WavLM과 다이نام릭 윈도우에 중요 패턴 패딩을 추가한 전처리 기법이다.

본 연구의 실험 결과로 볼 때, 제안한 전처리

기법을 적용하였을 때 기존 방법에 비해 약 3%의 성능 향상이 이루어졌다. 그러나, "중요 패턴 패딩 기법"의 적용은 성능 저하로 이어졌는데, 이는 패딩값에 중요 정보를 반영함에 따라 모델 학습 과정에서 과적합이 발생했기 때문으로 추정된다. 이러한 실험 결과는 본 연구에서 제안하는 전처리 기법의 잠재력과 한계를 동시에 보여준다.


이런 결과를 바탕으로, 본 연구는 음성 데이터 전처리에 대한 새로운 접근법을 제시하며, 음성 인식 및 분류를 포함한 다양한 음성 데이터 관련 분야에서 활용할 수 있음을 시사하였다. 이를 통해 처리 속도와 메모리 효율성을 개선하고 모델 성능을 향상시킬 수 있는 전처리 기법의 중요성을 강조하였다.

그러나 "중요 패턴 패딩 기법"의 문제점을 해결하고 이를 효과적으로 활용할 수 있는 방법에 대한 추가적인 연구가 필요하다는 것이 확인되었다. 이후의 연구에서는 이 문제점을 해결하고, 제안한 기법을 다양한 음성 데이터 분야에 적용하여 그 효과를 더욱 검증하는 방향으로 진행될 것으로 기대된다. 이렇게 함으로써, 본 연구가 제안하는 전처리 기법이 음성 데이터 처리를 위한 새로운 패러다임의 시작점이 될 수 있을 것이다. 향후 연구를 통해 다양한 음성 데이터에 대해 적용 가능한 보다 효율적이고 정교한 전처리 방법을 개발하는 것이 앞으로의 연구 과제로 남아있다.

참고문헌

- [1] Ye, Jiaxin, et al. "Temporal Modeling Matters: A Novel Temporal Emotional Modeling Approach for Speech Emotion Recognition." ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023.
- [2] Chen, Shuaiqi, et al. "DWFormer: Dynamic Window Transformer for Speech Emotion Recognition." ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023.
- [3] Lieskovská, Eva, et al. "A review on speech emotion recognition using deep learning and attention mechanism." Electronics 10.10 (2021): 1163.
- [4] Zou, Heqing, et al. "Speech emotion recognition with co-attention based multi-level acoustic information." ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022.
- [5] Li, P.; Song, Y.; McLoughlin, I.V.; Guo, W.; Dai, L.-R. An Attention Pooling based Representation Learning Method for Speech Emotion Recognition. In Proceedings of the Interspeech 2018, Hyderabad, India, 2-6 September 2018; International Speech Communication Association: Hyderabad, India, 2018.

- [6] Chen, M.; He, X.; Yang, J.; Zhang, H. 3-D Convolutional Recurrent Neural Networks with Attention Model for Speech Emotion Recognition. IEEE Signal Process. Lett. 2018, 25, 1440-1444.
- [7] 정용주, and 곽진열. "Attention CRNN 에 기반한 오디오 이벤트 검출." 한국전자통신학회 논문지 15.3 (2020): 465-472.
- [8] 이상현, 김재동, and 고한석. "강인한 감정 특징 추출을 위한 End-to-end 기반의 CRNN-GLU-ATT 모델." 전자공학회논문지 57.10 (2020): 45-55.



김기원

2018년~현재 인하대학교 정보통신공학과 학사과정 재학중.
관심분야는 음성 인식, 임베디드



곽준형

2020년~현재 인하대학교 정보통신공학과 학사과정 재학중.
관심분야는 AI, 자연어처리



서주형

2018년~현재 인하대학교 정보통신공학과 학사과정 재학중.
관심분야는 Cloud, DevOps